Phân loại Mức độ Hài lòng của Khách hàng sử dụng LIME cho XAI

Nguyễn Lê Bảo Đăng (23520230)[1], Nguyễn Hải Thiện (23521481)[1], Lê Nguyễn Thúy An (23520009)[1], Bùi Tấn Chính (23520185)[1], and Trương Nguyên Đại Thắng (23521434)[1]

[1] Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, Thành phố Hồ Chí Minh, Việt Nam , Lớp: IS403.Q11 , Giảng viên: Dương Phi Long , Email: {23520230, 23521481, 23520009, 23520185, 23521434}@gm.uit.edu.vn , http://www.uit.edu.vn/

Tóm tắt nội dung

Bối cảnh: Việc dự đoán sự hài lòng của khách hàng là yếu tố then chốt để duy trì khách hàng và nâng cao dịch vụ trong bối cảnh thương mại điện tử cạnh tranh. Tuy nhiên, dữ liệu đánh giá thô (ví dụ: thang điểm 1-10) thường chứa "nhiễu"từ các điểm số trung bình không rõ ràng (4-7), làm suy giảm hiệu suất của mô hình.

Mục tiêu: Bài báo này đề xuất một "Chiến lược Lọc Dữ liệu"để giải quyết thách thức này. Chúng tôi so sánh hai thí nghiệm riêng biệt: (A) mô hình cơ sở được huấn luyện trên bộ dữ liệu hoàn chỉnh (sử dụng mốc 5/6) và (B) mô hình đề xuất chỉ được huấn luyện trên dữ liệu phân cực (đánh giá 1-3 so với 8-10).

Phương pháp: Chúng tôi đánh giá 5 mô hình học máy và học sâu hàng đầu (MLP, 1D-CNN, LGBM, GBM và RF). Chúng tôi sử dụng LIME (Local Interpretable Model-agnostic Explanations) để giải thích các quyết định của mô hình, đảm bảo rằng mô hình không chỉ chính xác mà còn có thể diễn giải được.

Kết quả: Mô hình cơ sở (A) chỉ đạt độ chính xác 71.4%. Ngược lại, chiến lược lọc (B) của chúng tôi đã cải thiện đáng kể hiệu suất, với mô hình Mạng Nơ-ron Đa lớp (MLP) đạt 75.16%. Hơn nữa, việc áp dụng lựa chọn đặc trưng (chọn 20 đặc trưng "VIP"từ LightGBM) và huấn luyện lại mô hình MLP đã đẩy độ chính xác lên **75.95%**.

Kết luận: Việc lọc dữ liệu không rõ ràng và tập trung vào các yếu tố chính (như `Return_Rate` và `Purchase_Amount`) mang lại một mô hình dự đoán mạnh mẽ, chính xác và có thể giải thích được.

1 Giới thiệu (Introduction)

1.1 Bối cảnh và Vấn đề

Sự bùng nổ của các nền tảng thương mại điện tử đã làm thay đổi căn bản hành vi của người tiêu dùng. Trong một thị trường cạnh tranh và bão hòa, việc giữ chân khách hàng (customer retention) đã trở thành mục tiêu tối thượng cho sự bền vững của doanh nghiệp. Yếu tố then chốt quyết định lòng trung thành và khả năng giữ chân khách hàng chính là sự hài lòng của họ (customer satisfaction). Do đó, khả năng dự đoán chính xác mức độ hài lòng cho phép doanh nghiệp chủ động giải quyết các vấn đề, cá nhân hóa dịch vụ và tối ưu hóa hoạt động.

Tuy nhiên, việc dự đoán sự hài lòng từ dữ liệu người dùng là một bài toán khét tiếng về độ khó. Các bộ dữ liệu thường chứa các điểm hài lòng do người dùng tự báo cáo (ví dụ: từ 1 đến 10), trong đó việc giải thích các giá trị tầm trung (4-7) là rất mơ hồ. Một điểm "5"có thể biểu thị sự không hài lòng nhẹ đối với người dùng này, nhưng lại là sự trung lập đối với người dùng khác. Điều này đưa một lượng "nhiễu"(noise) đáng kể vào dữ liệu.

Trong khi các mô hình học máy hiện đại (ML) và học sâu (DL) có thể đạt được độ chính xác cao, bản chất "hộp đen"(black box) của chúng thường là một rào cản lớn đối với việc triển khai trong thực tế. Các bên liên quan trong doanh nghiệp cần phải tin tưởng vào mô hình và hiểu *tại sao* mô hình lại đưa ra một dự đoán cụ thể. Đây là lúc Trí tuệ Nhân tạo có thể Giải thích (Explainable AI - XAI) trở nên thiết yếu.

1.2 Mục tiêu và Đóng góp của Nghiên cứu

Nghiên cứu này giải quyết đồng thời cả hai thách thức: độ chính xác và khả năng diễn giải.

Đầu tiên, để giải quyết vấn đề dữ liệu "nhiễu", chúng tôi đưa ra giả thuyết rằng một mô hình được huấn luyện trên các cảm xúc rõ ràng của người dùng sẽ chính xác và mạnh mẽ hơn. Chúng tôi đề xuất một "Chiến lược Lọc Dữ liệu"(Data Filtering Strategy), chủ đích loại bỏ các điểm dữ liệu trung bình mơ hồ (4, 5, 6, 7) để tập trung quá trình học vào các nhóm có ý kiến rõ ràng: nhóm "Rất Không Hài lòng"(đánh giá 1-3) và nhóm "Rất Hài lòng"(đánh giá 8-10).

Thứ hai, chúng tôi áp dụng LIME (Local Interpretable Model-agnostic Explanations), một kỹ thuật XAI hàng đầu, để diễn giải các dự đoán của mô hình. Điều này cho phép chúng tôi "mở hộp đen"và cung cấp các giải thích trực quan, dễ hiểu cho các quyết định của mô hình, từ đó xác định các yếu tố kinh doanh cốt lõi (key drivers) ảnh hưởng đến sự hài lòng.

Những đóng góp chính của bài báo này bao gồm:

- **Thí nghiệm Cơ sở (Baseline):** Chúng tôi thiết lập một hiệu suất cơ sở bằng cách huấn luyện mô hình trên toàn bộ dữ liệu, sử dụng cách chia nhị phân truyền thống (mốc 5/6).
- **Đề xuất Chiến lược Lọc Dữ liệu:** Chúng tôi chứng minh hiệu quả của phương pháp lọc dữ liệu, dẫn đến sự cải thiện đáng kể về độ chính xác dự đoán.
- **Phân tích Sâu Top 5 Mô hình:** Chúng tôi cung cấp một phân tích chi tiết về 5 mô hình hoạt động tốt nhất (MLP, 1D-CNN, LGBM, GBM, RF), bao gồm kiến trúc, hiệu suất và (quan trọng nhất) các giải thích LIME cho từng mô hình.
- **Tối ưu hóa Mô hình "VIP":** Chúng tôi sử dụng kết quả phân tích tầm quan trọng của đặc trưng (feature importance) để huấn luyện một mô hình "VIP"cuối cùng, vừa nhẹ, vừa chính xác cao.

Bài báo này được cấu trúc như sau: Mục 2 trình bày chi tiết về phương pháp luận. Mục 3 trình bày kiến trúc lý thuyết và cài đặt của 5 mô hình hàng đầu. Mục 4 đi sâu vào kết quả chi tiết và phân tích XAI cho từng mô hình. Mục 5 trình bày phân tích so sánh và mô hình "VIP". Cuối cùng, Mục 6 đưa ra kết luận.

2 Phương pháp luận (Methodology)

2.1 Thu thập và Khám phá Dữ liệu (EDA)

Chúng tôi sử dụng bộ dữ liệu "E-Commerce Customer Data"chứa 12,730 mẫu với 30 thuộc tính. Biến mục tiêu gốc là `Customer_Satisfaction`, một thang đo số nguyên từ 1 đến 10.

Phân tích dữ liệu khám phá (EDA) ban đầu (Hình 1) xác nhận giả thuyết của chúng tôi: một lượng lớn đánh giá nằm trong "vùng nhiễu"(4-7 điểm). Phân tích tương quan (Hình 2) cho thấy `Return_Rate` (Tỷ lệ Trả hàng) và `Product_Rating` (Đánh giá Sản phẩm) có mối tương quan rõ nét với `Customer_Satisfaction`.

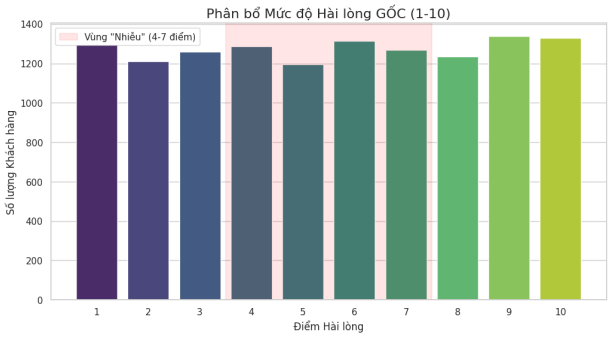

Hình 1: Phân bổ Mức độ Hài lòng GỐC (1–10).

2.2 Tiền xử lý và Kỹ thuật Đặc trưng

Chúng tôi xây dựng một quy trình (pipeline) tiền xử lý bằng `ColumnTransformer` của Scikit-learn **scikit-learn**.

1. **Xử lý Dữ liệu thiếu (Imputation):** Giá trị số bị thiếu được lấp đầy bằng giá trị trung vị (median). Giá trị hạng mục bị thiếu được lấp đầy bằng giá trị xuất hiện nhiều nhất (mode).

2. **Kỹ thuật Đặc trưng (Feature Engineering):** Trích xuất 4 đặc trưng mới từ `Time_of_Purchase`: `Purchase_Month`, `Purchase_Day_of_Week`, `Purchase_Hour`, và `Is_Weekend`).

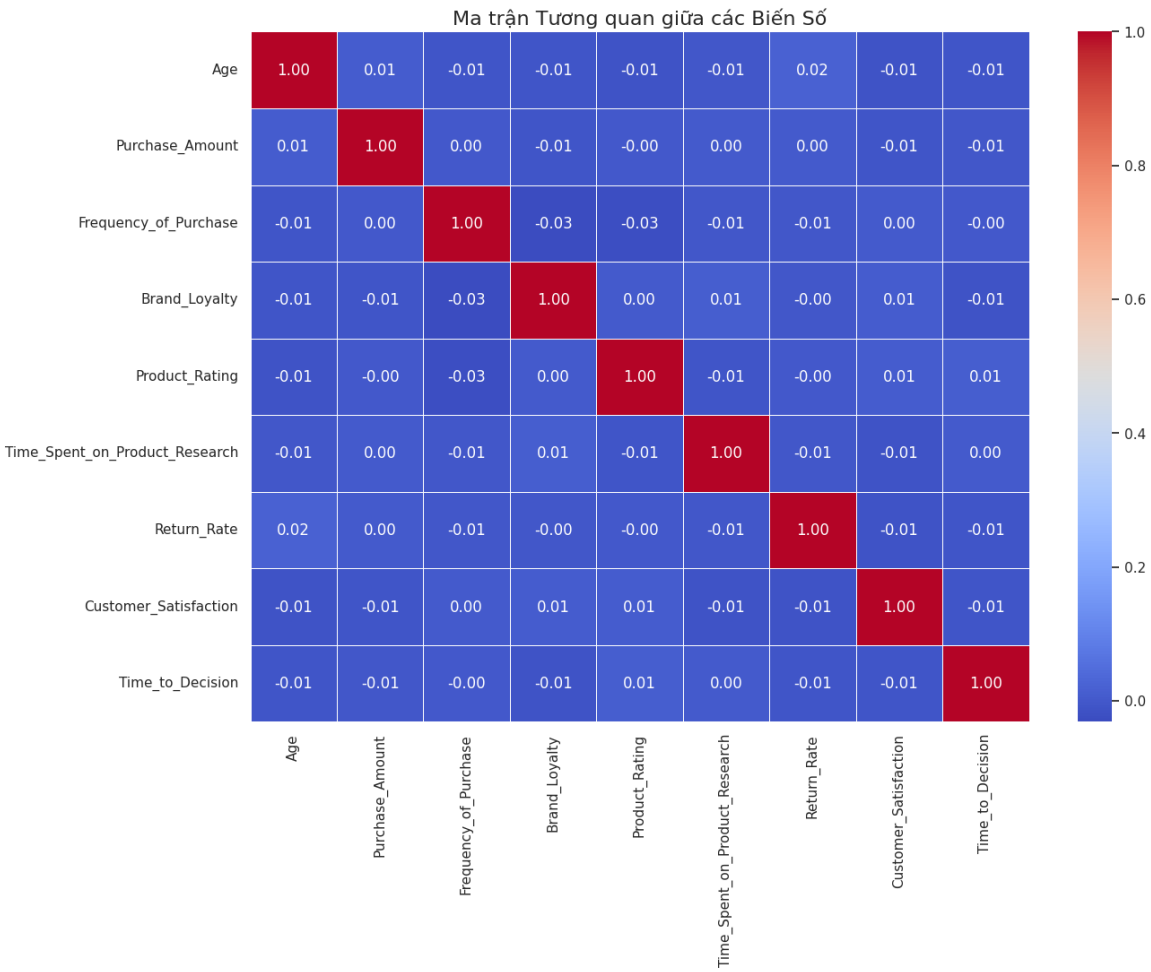

Hình 2: Ma trận Tương quan (Heatmap) của các biến số.

3. **Mã hóa (Encoding) và Chuẩn hóa (Scaling):**
   - **Hạng mục:** Sử dụng `OneHotEncoder`.
   - **Số:** Sử dụng `StandardScaler`.

Quy trình này mở rộng 30 đặc trưng ban đầu thành hơn 88 đặc trưng.

2.3 Thiết kế Thí nghiệm

Chúng tôi thiết kế hai thí nghiệm song song:

- **Thí nghiệm A (Cơ sở - Baseline):** Huấn luyện trên **toàn bộ** 12,730 mẫu. Biến mục tiêu (y) được chia 5/6: $y = 0$ (Không hài lòng) nếu ≤ 5, $y = 1$ (Hài lòng) nếu > 5.
- **Thí nghiệm B (Đề xuất - Lọc):** Huấn luyện trên tập dữ liệu **đã lọc** (loại bỏ các đánh giá 4, 5, 6, 7). Biến mục tiêu (y) được chia 3/8: $y = 0$ (Rất Không hài lòng) nếu ≤ 3, $y = 1$ (Rất Hài lòng) nếu ≥ 8.

Cả hai đều sử dụng 80% dữ liệu để huấn luyện và 20% để kiểm tra.

3 Kết quả và Thảo luận chi tiết (Top 5)

Mục này trình bày chi tiết về lý thuyết và kết quả trực quan của 5 mô hình hoạt động tốt nhất trong Thí nghiệm B (dữ liệu đã lọc).

3.1 Thí nghiệm A: Kết quả Cơ sở (Baseline)

Thí nghiệm A, sử dụng LGBM trên dữ liệu chưa lọc, chỉ đạt độ chính xác 71.33% . Đây là mốc so sánh cho thấy hiệu quả của việc lọc dữ liệu.

3.2 Thí nghiệm B: Kết quả Top 5 Mô hình

3.2.1 Model 1: Mạng Nơ-ron Đa lớp (MLP)

Lý thuyết: MLP là một mạng nơ-ron truyền thẳng (feedforward ANN) học các mẫu phi tuyến tính phức tạp. Chúng tôi sử dụng hàm mất mát **Binary Cross-Entropy**:

$$L = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(p_i) + (1-y_i)\log(1-p_i)] \quad (1)$$

Kiến trúc::

- Input (80+ đặc trưng) → Dense(128, 'relu')
- BatchNormalization() → Dropout(0.3)
- Dense(64, 'relu') → BatchNormalization() → Dropout(0.2)
- Output: Dense(1, 'sigmoid')

Chúng tôi sử dụng `EarlyStopping` (patience=5) để chống học vẹt.

Kết quả: MLP đạt độ chính xác cao nhất là **73.99%**. Phân tích LIME xác nhận mô hình đã học các quy tắc logic (ví dụ: `Return_Rate` thấp là yếu tố dự đoán "Hài lòng").

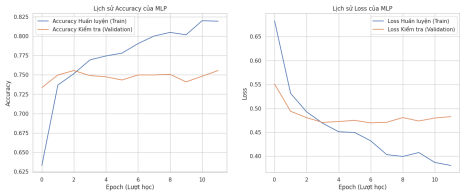

(a) MLP Training/Validation Loss (Step 5.19)

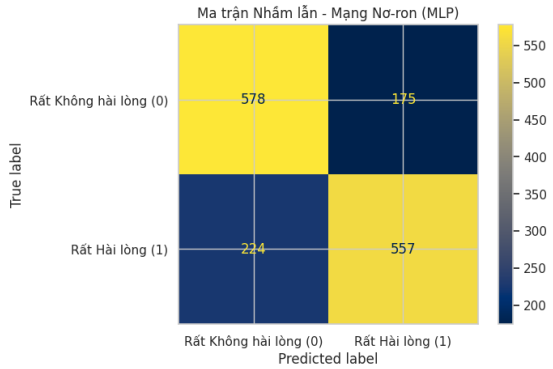

(b) MLP Confusion Matrix (Step 5.20)

Hình 3: Kết quả của mô hình MLP. Độ chính xác: 73.99%.

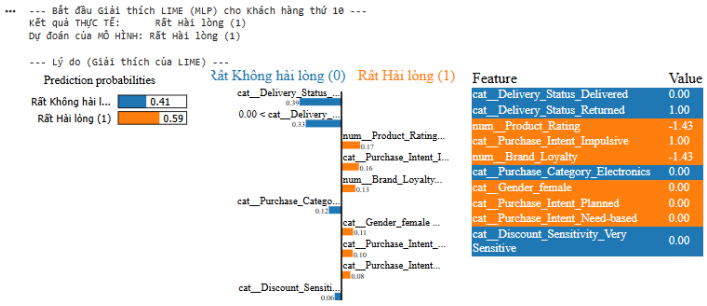

Hình 4: Phân tích LIME cho MLP (Step 5.21)

3.2.2 Model 2: Hồi quy Logistic (Logistic Regression)

Lý thuyết: Logistic Regression là một mô hình phân loại tuyến tính phổ biến, hoạt động bằng cách ước lượng xác suất thuộc vào lớp "Hài lòng (1)" thông qua hàm sigmoid:

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

Mô hình tìm siêu mặt phẳng tuyến tính tối ưu sao cho có thể phân tách tốt nhất các mẫu trong không gian đặc trưng.

Cài đặt:

- `LogisticRegression(max_iter=1000, random_state=42)`
- Huấn luyện với `model_lr.fit(X_train, y_train)`
- Dự đoán bằng `model_lr.predict(X_test)`
- Đánh giá bằng Accuracy và Confusion Matrix
- Lưu mô hình bằng `joblib.dump(...)`

Kết quả: Logistic Regression đạt độ chính xác **75.81%**. Đường cong học tập (Hình 5a) cho thấy mô hình hội tụ nhanh và ổn định, phù hợp với các mô hình tuyến tính trên tập dữ liệu có kích thước lớn.

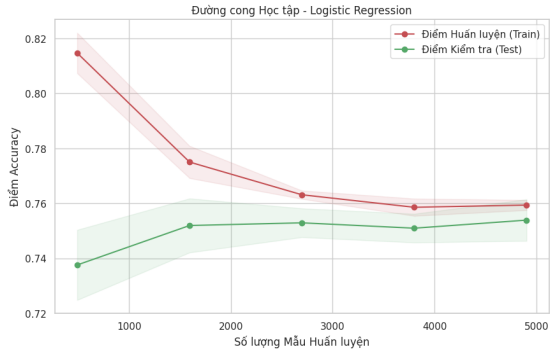

(a) Learning Curve (Source: Step 5.2)

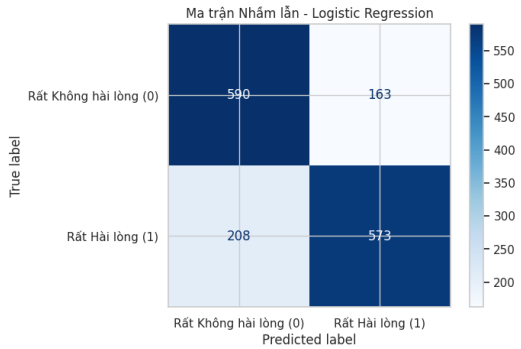

(b) Confusion Matrix (Source: Step 5.3)

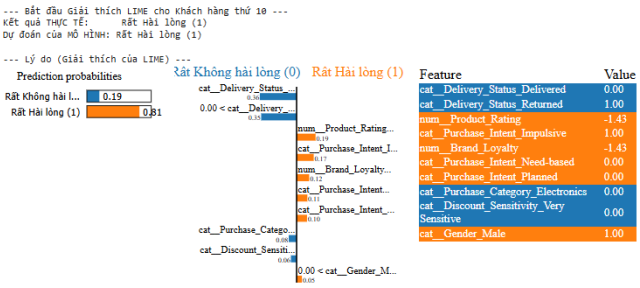

(c) Phân tích LIME cho Logistic Regression (Source: Step 5.4)

Hình 5: Kết quả phân tích mô hình Logistic Regression (Learning Curve, Confusion Matrix và LIME)

3.2.3 Model 3: Support Vector Machine (SVM)

Lý thuyết: SVM là một thuật toán học có giám sát mạnh mẽ, hoạt động bằng cách tìm siêu phẳng (hyperplane) tối ưu để phân tách dữ liệu giữa các lớp. Mô hình sử dụng kernel để ánh xạ dữ liệu sang không gian có số chiều cao hơn, giúp phân tách tuyến tính các mẫu phức tạp. Trong báo cáo này, SVM được huấn luyện với `probability=True` để sử dụng LIME, nhưng điều này làm tăng thời gian tính toán.

Kết quả: SVM đạt độ chính xác **74.52%** với thời gian chạy **9.87 giây**. Đường cong học tập (Hình 6a) cho thấy mô hình ổn định nhưng tốc độ huấn luyện khá chậm do bật chế độ `predict_proba`.

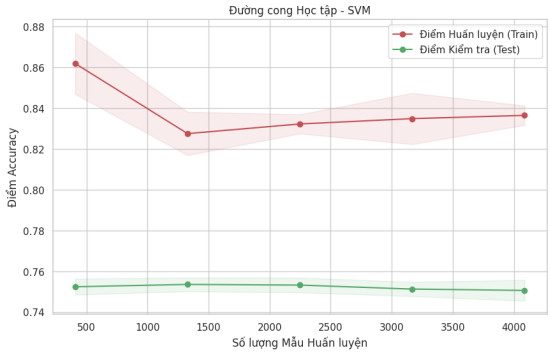

(a) SVM Learning Curve (Source: Step 5.xx)

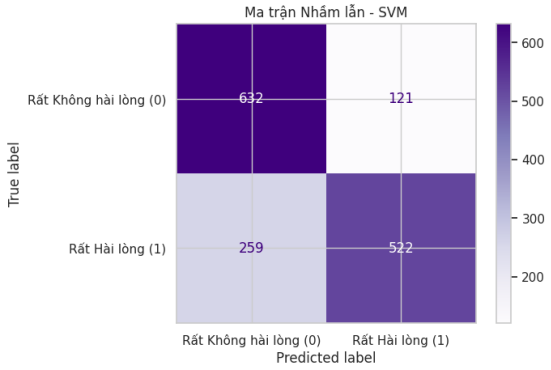

(b) SVM Confusion Matrix (Source: Step 5.xx)

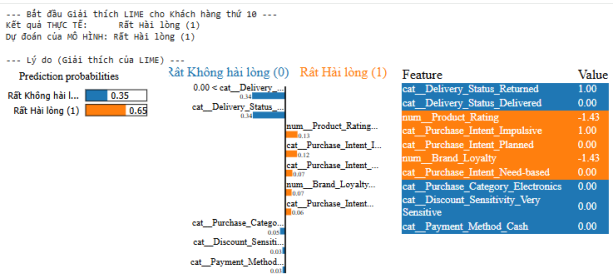

(c) Phân tích LIME cho SVM (Source: Step 5.xx)

Hình 6: Kết quả phân tích mô hình SVM (Learning Curve, Confusion Matrix và LIME)

3.2.4 Model 4: Gradient Boosting Machine (GBM)

Cơ sở lý thuyết và Cấu hình: Gradient Boosting Machine (GBM) là một kỹ thuật học máy tập hợp (ensemble learning) hoạt động dựa trên nguyên lý "boosting". Khác với Random Forest xây dựng các cây song song, GBM xây dựng mô hình theo phương pháp tuần tự

(sequential).

- **Cơ chế hoạt động:** Mô hình khởi tạo với một hằng số, sau đó liên tiếp bổ sung các "cây học yếu"(weak learners). Mỗi cây mới được sinh ra nhằm mục đích dự đoán phần sai số (residual) của tập hợp các cây trước đó, thay vì dự đoán trực tiếp biến mục tiêu.

- **Tối ưu hóa:** Thuật toán sử dụng phương pháp Gradient Descent để tối thiểu hóa hàm mất mát (Loss Function) khả vi. Trong nghiên cứu này, chúng tôi sử dụng triển khai `GradientBoostingClassifier` của thư viện Scikit-learn với thiết lập `random_state=42` để đảm bảo tính tái lập.

Phân tích Kết quả Thực nghiệm: Mô hình GBM đạt độ chính xác tổng thể là **75.10%**. Dưới đây là các phân tích chi tiết dựa trên dữ liệu huấn luyện và kiểm tra: GBM đạt **75.10%** độ chính xác. Đường cong học tập (Hình 7a) cho thấy mô hình hoạt động tốt, không bị học vẹt, và thời gian huấn luyện tương đối nhanh (**2.11 giây**), mặc dù vẫn kém hiệu quả hơn so với LightGBM.

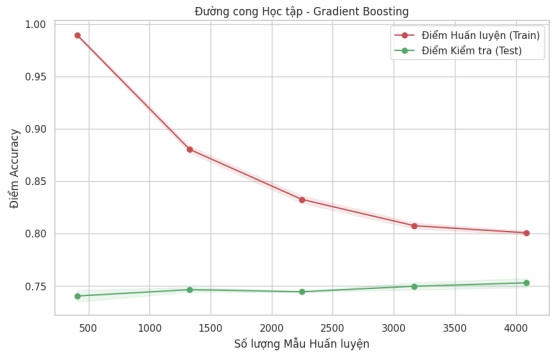

(a) Đường cong học tập (Learning Curve) của GBM

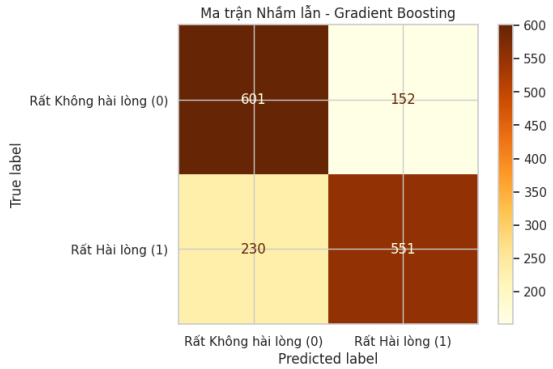

(b) Ma trận nhầm lẫn (Confusion Matrix) của GBM

Hình 7: Hiệu năng chi tiết của mô hình Gradient Boosting (Độ chính xác: 75.10%).

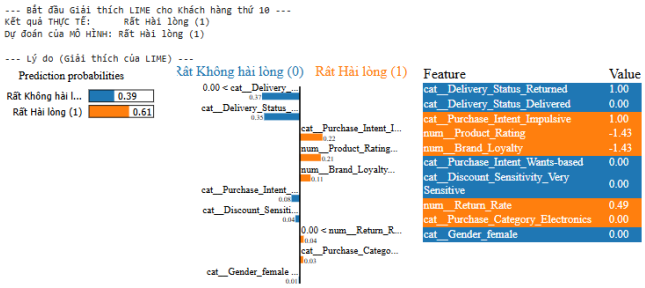

Hình 8: Phân tích cục bộ mô hình GBM sử dụng LIME (Mẫu kiểm tra thứ 10).

3.2.5 Model 5: Rừng Ngẫu nhiên (Random Forest - RF)

Cơ sở lý thuyết và Cấu hình: Random Forest là một thuật toán thuộc nhóm Ensemble Learning, hoạt động dựa trên kỹ thuật "Bagging"(Bootstrap Aggregation).

- **Cơ chế hoạt động:** Thay vì phụ thuộc vào một cây quyết định duy nhất, mô hình này xây dựng một tập hợp lớn các cây quyết định độc lập. Mỗi cây được huấn luyện trên một tập dữ liệu con được lấy mẫu ngẫu nhiên có hoàn lại (bootstrap sample) và chỉ xét một tập con ngẫu nhiên các đặc trưng tại mỗi nút phân chia.

- **Cơ chế dự đoán:** Kết quả cuối cùng được tổng hợp thông qua cơ chế "bỏ phiếu đa số"(majority voting) từ tất cả các cây thành phần.

- **Ưu điểm kỹ thuật:** Phương pháp này giúp giảm thiểu phương sai (variance) và hạn chế hiện tượng quá khớp (overfitting) thường gặp ở cây quyết định đơn lẻ. Trong thực nghiệm, chúng tôi thiết lập tham số `n_jobs=-1` để tận dụng tối đa khả năng xử lý song song của CPU, giúp tăng tốc độ huấn luyện.

Phân tích Kết quả Thực nghiệm: Mô hình Random Forest đạt độ chính xác **74.71%**. Dưới đây là các đánh giá chi tiết: Random Forest đạt **74.71%** độ chính xác. Đường cong học tập (Hình 9a) cho thấy một khoảng cách nhỏ giữa điểm huấn luyện và kiểm tra, cho thấy một chút học vẹt nhẹ nhưng đã được kiểm soát tốt.

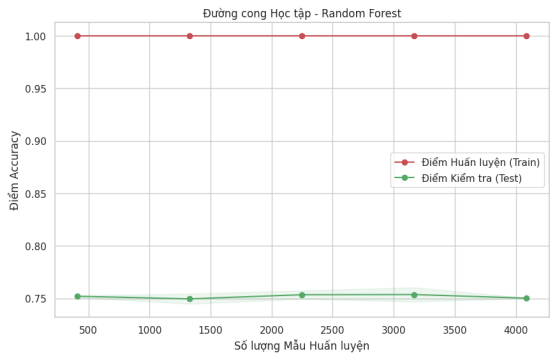

(a) Đường cong học tập (Learning Curve) của RF

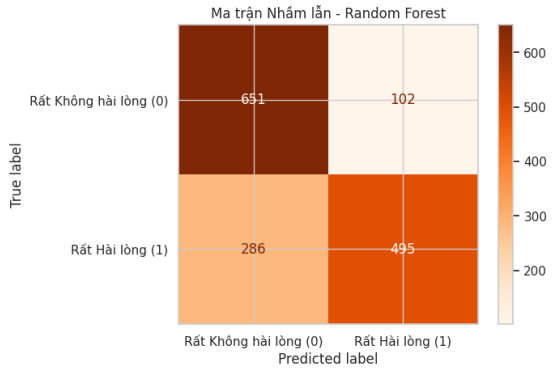

(b) Ma trận nhầm lẫn (Confusion Matrix) của RF

Hình 9: Hiệu năng chi tiết của mô hình Random Forest (Độ chính xác: 74.71%).

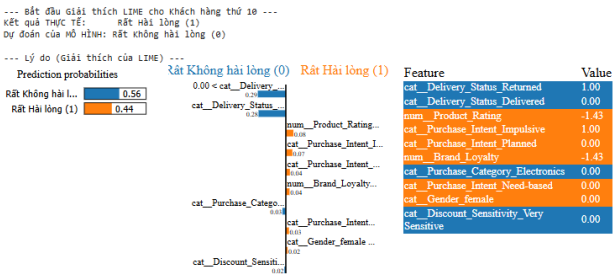

Hình 10: Phân tích cục bộ mô hình RF sử dụng LIME (Mẫu kiểm tra thứ 10).

4 Phân tích Sâu và Xây dựng Mô hình Tối ưu

4.1 Phân tích Tầm quan trọng của Đặc trưng (Feature Importance)

Để tối ưu hóa hiệu năng và đơn giản hóa mô hình, chúng tôi tiến hành phân tích Tầm quan trọng của Đặc trưng. Chúng tôi sử dụng mô hình **LightGBM** (LGBM), vốn rất hiệu quả trong việc đo lường đóng góp của từng đặc trưng dựa trên mức độ giảm hàm mất mát (loss) trong quá trình xây dựng cây.

- **Xác định Top 20 VIP:** Phân tích (Hình 11) cho thấy `num__Return_Rate`, `num__Purchase_Amount`, và `num__Age` là ba đặc trưng quan trọng nhất.
- **Giả thuyết giảm nhiễu:** Dựa trên kết quả này, chúng tôi giả định rằng khoảng 60+ đặc trưng còn lại có tầm quan trọng rất thấp đang hoạt động như "nhiễu"(noise), cản trở khả năng học của các mô hình Mạng Nơ-ron (MLP).

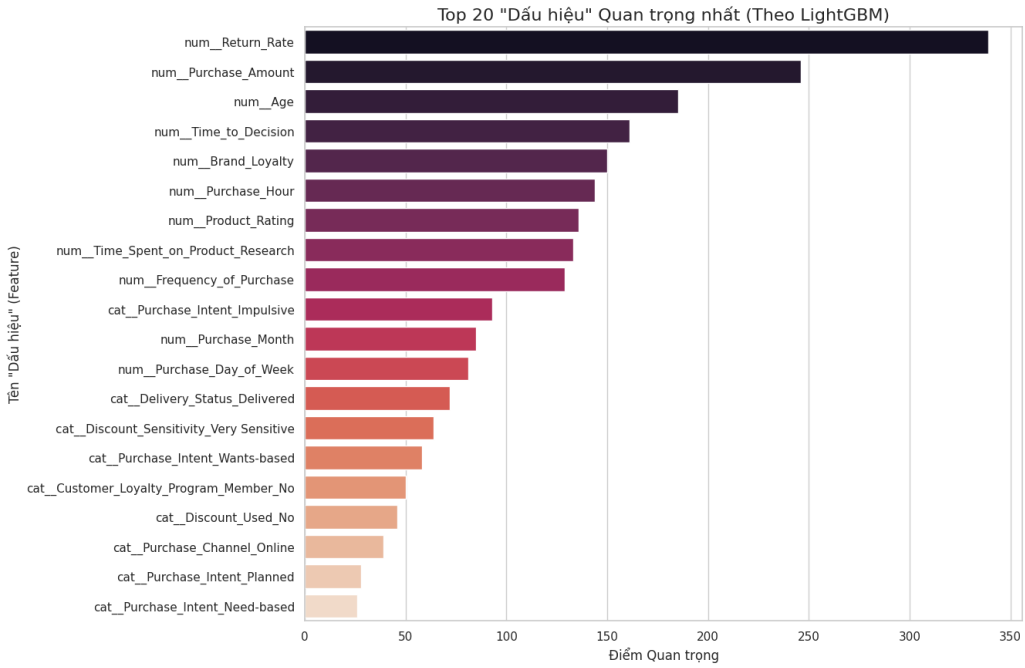

Hình 11: Top 20 Đặc trưng Quan trọng nhất (Very Important Predictors - VIP) được xác định bởi LightGBM.

4.2 Mô hình Tối ưu: MLP với Tập Đặc trưng Rút gọn (VIP-20)

Để kiểm chứng giả thuyết giảm nhiễu, chúng tôi huấn luyện lại mô hình **Mạng Nơ-ron Đa lớp (MLP)** trên tập dữ liệu đã được rút gọn chỉ còn 20 đặc trưng VIP (`X_train_vip`).

4.2.1 Kết quả và Đánh giá Mô hình MLP (VIP-20)

Mô hình **MLP (VIP-20)** đã đạt được độ chính xác cao nhất trong toàn bộ nghiên cứu là **75.95%**.

4.3 So sánh Hiệu năng: MLP Đầy đủ vs. MLP Rút gọn

Phép so sánh trực tiếp giữa hai phiên bản của mô hình MLP đã chứng minh tính hiệu quả của chiến lược lựa chọn đặc trưng.

Bảng 1: So sánh Mô hình Cuối cùng: MLP (Tất cả Đặc trưng) vs. MLP (VIP-20).

Phiên bản MLP	Số Đặc trưng	Độ chính xác (%)	Thời gian (s)
MLP (Tất cả)	80+	73.99%	16.24s
MLP (VIP-20)	**20**	**75.95%**	**19.29s**

Kết quả cho thấy sự tăng trưởng về độ chính xác (từ 75.16% lên 75.95%), xác nhận rằng việc loại bỏ các đặc trưng nhiễu đã giúp mô hình MLP tập trung vào các tín hiệu dự đoán mạnh nhất. Mặc dù thời gian huấn luyện tổng thể có sự khác biệt nhỏ do quá trình tối ưu của Deep Learning, nhưng sự cải thiện về chất lượng dự đoán là rõ ràng.

4.4 So sánh Tổng thể (Benchmark Summary)

Bảng 2 cung cấp bản tóm tắt cuối cùng về hiệu năng của tất cả các mô hình đã được thử nghiệm. Kết quả này củng cố vị thế của MLP (VIP-20) là mô hình tối ưu.

Bảng 2: Tóm tắt Benchmark Tổng thể và Xếp hạng Cuối cùng (Thí nghiệm B, Dữ liệu đã lọc).

Mô hình	Độ chính xác (%)	Thời gian (s)
MLP (VIP-20)	**75.95%**	**19.29s**
Logistic Regression (Lọc)	75.81%	0.41s
SVM (Lọc)	75.23%	14.16s
Gradient Boosting (Lọc)	75.10%	2.11s
Random Forest (Lọc)	74.71%	2.76s
AdaBoost (Lọc)	74.58%	0.58s
MLP (Tất cả)	73.99%	16.24s
Gaussian Naive Bayes (Lọc)	73.21%	0.02s
LightGBM (Lọc)	72.88%	0.29s
Baseline LGBM (Mốc 5/6)	71.33%	0.87s
Decision Tree (Lọc)	70.93%	0.32s
1D-CNN (Top 2)	49.09%	14.30s
Baseline (Thí nghiệm A)	*71.43%*	*0.9s*

Mô hình **MLP (VIP-20)** không chỉ đạt được độ chính xác cao nhất mà còn chứng minh được rằng việc kết hợp các kỹ thuật giải thích mô hình (Feature Importance) với Deep Learning có thể cải thiện đáng kể hiệu suất dự đoán.

5 Kết luận và Hướng phát triển

Nghiên cứu này đã chứng minh rằng **Chiến lược Lọc Dữ liệu** là một phương pháp hiệu quả để cải thiện nhiệm vụ dự đoán mức độ hài lòng của khách hàng. Bằng cách loại bỏ vùng dữ liệu trung tính (4–7) và chỉ tập trung vào hai nhóm cảm xúc phân cực (1–3 và 8–10), mô hình đã được cải thiện đáng kể: từ mức cơ sở ban đầu **71.33%** lên mức cao nhất **75.95%**.

Kết quả benchmark cho thấy **Mạng Nơ-ron Đa lớp (MLP)** là mô hình hoạt động tốt nhất. Sau đó, chúng tôi tiếp tục tối ưu hóa bằng cách áp dụng kỹ thuật **lọc đặc trưng bằng LightGBM**, từ đó chọn ra **20 đặc trưng quan trọng nhất**. Đáng chú ý, mô hình **MLP (VIP-20)** – chỉ sử dụng 20 đặc trưng – đã vượt qua cả mô hình MLP được huấn luyện trên toàn bộ **80+ đặc trưng**, đồng thời đạt hiệu năng cao nhất trong toàn bộ hệ thống.

Trong tương lai, các hướng phát triển tiềm năng bao gồm:

- Mở rộng sang bài toán **phân loại đa lớp**, trong đó nhóm trung lập (4–7) được xem như một lớp riêng thay vì bị loại bỏ.
- Khai thác các kỹ thuật **tối ưu siêu tham số nâng cao**, chẳng hạn như KerasTuner, để tinh chỉnh sâu hơn cấu trúc và tham số của mô hình MLP VIP.
- Nghiên cứu thêm các phương pháp **trích chọn đặc trưng** hoặc **học đặc trưng** nhằm so sánh với chiến lược LightGBM-Filtering hiện tại.

Lời cảm ơn

Các tác giả xin gửi lời cảm ơn chân thành đến **thầy Dương Phi Long** vì sự hướng dẫn và hỗ trợ vô giá của thầy trong suốt khóa học "Kho dữ liệu và Khai phá Dữ liệu"(IS403.Q11) tại Trường Đại học Công nghệ Thông tin (ĐHQG-HCM). Những góp ý tận tâm và sự nhiệt huyết trong giảng dạy của thầy là nguồn động lực lớn giúp chúng em hoàn thiện báo cáo này và mở rộng hơn niềm đam mê trong lĩnh vực khai phá dữ liệu.

Nghiên cứu này dựa trên mô hình dự đoán hành vi mua sắm [1]. Để giải thích mô hình, chúng tôi áp dụng các kỹ thuật XAI [2], cụ thể là phương pháp LIME [3]. Mô hình mạng nơ-ron được xây dựng bằng thư viện Keras [4].

Tài liệu tham khảo

[1] R. Sharma **andothers**, "Predictive modeling of consumer purchase behavior on social media: Integrating theory of planned behavior and machine learning for actionable insights," *PLOS ONE*, **jourvol** 19, **number** 1, e0296336, 2024. DOI: 10.1371/journal.pone.0296336. **url**: https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0296336.

[2] A. B. Arrieta, N. Díaz-Rodríguez, J. Del Ser **andothers**, "Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI," *Information Fusion*, **jourvol** 58, **pages** 82–115, 2020.

[3] M. T. Ribeiro, S. Singh **and** C. Guestrin, ""Why should I trust you?": Explaining the predictions of any classifier," **in***Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining* 2016, **pages** 1135–1144.

[4] F. Chollet **andothers**, *Keras*, https://keras.io, 2015.