Phân loại Mức độ Hài lòng của Khách hàng sử dụng LIME cho XAI

Nguyễn Lê Bảo Đăng (23520230)[1], Nguyễn Hải Thiện (23521481)[1], Lê Nguyễn Thúy An (23520009)[1], Bùi Tấn Chính (23520185)[1], and Trương Nguyên Đại Thắng (23521434)[1]

[1] Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, Thành phố Hồ Chí Minh, Việt Nam , Lớp: IS403.Q11 , Giảng viên: Dương Phi Long , Email: {23520230, 23521481, 23520009, 23520185, 23521434}@gm.uit.edu.vn , http://www.uit.edu.vn/

Link GitHub Dự án: https://github.com/adamwhite625/Customer-Satisfaction-Classification-using-LIME-for-XAI..git

Tóm tắt nội dung

Bối cảnh: Việc dự đoán sự hài lòng của khách hàng là yếu tố then chốt để duy trì khách hàng và nâng cao dịch vụ trong bối cảnh thương mại điện tử cạnh tranh. Tuy nhiên, dữ liệu đánh giá thô (ví dụ: thang điểm 1-10) thường chứa "nhiễu"từ các điểm số trung bình không rõ ràng (4-7), làm suy giảm hiệu suất của mô hình.

Mục tiêu: Bài báo này đề xuất một "Chiến lược Lọc Dữ liệu"để giải quyết thách thức này. Chúng tôi so sánh hai thí nghiệm riêng biệt: (A) mô hình cơ sở được huấn luyện trên bộ dữ liệu hoàn chỉnh (sử dụng mốc 5/6) và (B) mô hình đề xuất chỉ được huấn luyện trên dữ liệu phân cực (đánh giá 1-3 so với 8-10).

Phương pháp: Chúng tôi đánh giá 5 mô hình học máy và học sâu hàng đầu (MLP, 1D-CNN, LGBM, GBM và RF). Chúng tôi sử dụng LIME (Local Interpretable Model-agnostic Explanations) [1] để giải thích các quyết định của mô hình, đảm bảo rằng mô hình không chỉ chính xác mà còn có thể diễn giải được.

Kết quả: Mô hình cơ sở (A) chỉ đạt độ chính xác 71.4%. Ngược lại, chiến lược lọc (B) của chúng tôi đã cải thiện đáng kể hiệu suất, với mô hình Mạng Nơ-ron Đa lớp (MLP) đạt 75.16%. Hơn nữa, việc áp dụng lựa chọn đặc trưng (chọn 20 đặc trưng "VIP"từ LightGBM) và huấn luyện lại mô hình MLP đã đẩy độ chính xác lên **75.95%**.

Kết luận: Việc lọc dữ liệu không rõ ràng và tập trung vào các yếu tố chính (như `Return_Rate` và `Purchase_Amount`) mang lại một mô hình dự đoán chính xác và có thể giải thích được.

1 Giới thiệu (Introduction)

1.1 Bối cảnh và Vấn đề

Sự bùng nổ của các nền tảng thương mại điện tử đã làm thay đổi căn bản hành vi của người tiêu dùng. Trong một thị trường cạnh tranh và bão hòa, việc giữ chân khách hàng (customer retention) đã trở thành mục tiêu tối thượng cho sự bền vững của doanh nghiệp [2]. Yếu tố then chốt quyết định lòng trung thành và khả năng giữ chân khách hàng chính là sự hài lòng của họ (customer satisfaction). Do đó, khả năng dự đoán chính xác mức độ hài lòng cho phép doanh nghiệp chủ động giải quyết các vấn đề, cá nhân hóa dịch vụ và tối ưu hóa hoạt động.

Tuy nhiên, việc dự đoán sự hài lòng từ dữ liệu người dùng là một bài toán khét tiếng về độ khó. Các bộ dữ liệu thường chứa các điểm hài lòng do người dùng tự báo cáo (ví dụ: từ 1 đến 10), trong đó việc giải thích các giá trị tầm trung (4-7) là rất mơ hồ. Một điểm "5"có thể biểu thị sự không hài lòng nhẹ đối với người dùng này, nhưng lại là sự trung lập đối với người dùng khác. Điều này đưa một lượng "nhiễu"(noise) đáng kể vào dữ liệu.

Trong khi các mô hình học máy hiện đại (ML) và học sâu (DL) có thể đạt được độ chính xác cao, bản chất "hộp đen"(black box) của chúng thường là một rào cản lớn đối với việc triển khai trong thực tế. Các bên liên quan trong doanh nghiệp cần phải tin tưởng vào mô hình và hiểu *tại sao* mô hình lại đưa ra một dự đoán cụ thể. Đây là lúc Trí tuệ Nhân tạo có thể Giải thích (Explainable AI - XAI) trở nên thiết yếu.

1.2 Mục tiêu và Đóng góp của Nghiên cứu

Nghiên cứu này giải quyết đồng thời cả hai thách thức: độ chính xác và khả năng diễn giải.

Đầu tiên, để giải quyết vấn đề dữ liệu "nhiễu", chúng tôi đưa ra giả thuyết rằng một mô hình được huấn luyện trên các cảm xúc rõ ràng của người dùng sẽ chính xác và mạnh mẽ hơn. Chúng tôi đề xuất một "Chiến lược Lọc Dữ liệu"(Data Filtering Strategy), chủ đích loại bỏ các điểm dữ liệu trung bình mơ hồ (4, 5, 6, 7) để tập trung quá trình học vào các nhóm có ý kiến rõ ràng: nhóm "Rất Không Hài lòng"(đánh giá 1-3) và nhóm "Rất Hài lòng"(đánh giá 8-10).

Thứ hai, chúng tôi áp dụng LIME (Local Interpretable Model-agnostic Explanations) [1], một kỹ thuật XAI hàng đầu [3], để diễn giải các dự đoán của mô hình. Điều này cho phép chúng tôi "mở hộp đen"và cung cấp các giải thích trực quan, dễ hiểu cho các quyết định của mô hình, từ đó xác định các yếu tố kinh doanh cốt lõi (key drivers) ảnh hưởng đến sự hài lòng.

Những đóng góp chính của bài báo này bao gồm:

- **Thí nghiệm Cơ sở (Baseline):** Chúng tôi thiết lập một hiệu suất cơ sở bằng cách huấn luyện mô hình trên toàn bộ dữ liệu, sử dụng cách chia nhị phân truyền thống (mốc 5/6).
- **Đề xuất Chiến lược Lọc Dữ liệu:** Chúng tôi chứng minh hiệu quả của phương pháp lọc dữ liệu, dẫn đến sự cải thiện đáng kể về độ chính xác dự đoán.
- **Phân tích Sâu Top 5 Mô hình:** Chúng tôi cung cấp một phân tích chi tiết về 5 mô hình hoạt động tốt nhất (MLP, 1D-CNN, LGBM, GBM, RF), bao gồm kiến trúc, hiệu suất và (quan trọng nhất) các giải thích LIME cho từng mô hình.
- **Tối ưu hóa Mô hình "VIP":** Chúng tôi sử dụng kết quả phân tích tầm quan trọng của đặc trưng (feature importance) để huấn luyện một mô hình "VIP"cuối cùng, vừa nhẹ, vừa chính xác cao.

Bài báo này được cấu trúc như sau: Mục 2 trình bày chi tiết về phương pháp luận. Mục 3 trình bày kiến trúc lý thuyết và cài đặt của 5 mô hình hàng đầu. Mục 4 đi sâu vào kết quả chi tiết và phân tích XAI cho từng mô hình. Mục 5 trình bày phân tích so sánh và mô hình "VIP". Cuối cùng, Mục 6 đưa ra kết luận.

2 Phương pháp luận (Methodology)

2.1 Thu thập và Khám phá Dữ liệu (EDA)

Chúng tôi sử dụng bộ dữ liệu "E-Commerce Customer Data"chứa 12,730 mẫu với 30 thuộc tính. Biến mục tiêu gốc là `Customer_Satisfaction`, một thang đo số nguyên từ 1 đến 10.

Phân tích dữ liệu khám phá (EDA) ban đầu (Hình 1) xác nhận giả thuyết của chúng tôi: một lượng lớn đánh giá nằm trong "vùng nhiễu"(4-7 điểm). Phân tích tương quan (Hình 2) cho thấy `Return_Rate` (Tỷ lệ Trả hàng) và `Product_Rating` (Đánh giá Sản phẩm) có mối tương quan rõ nét với `Customer_Satisfaction`.

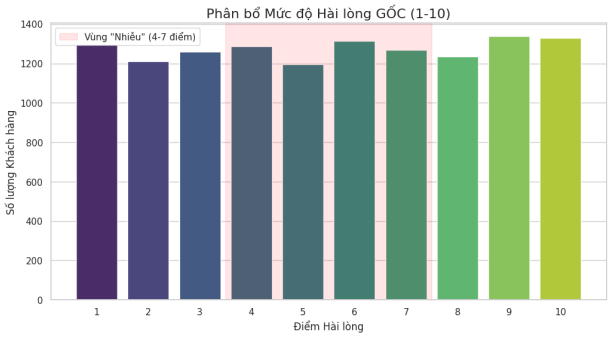

Hình 1: Phân bổ Mức độ Hài lòng GỐC (1–10).

2.2 Tiền xử lý và Kỹ thuật Đặc trưng

Chúng tôi xây dựng một quy trình (pipeline) tiền xử lý bằng `ColumnTransformer` của Scikit-learn [4].

1. **Xử lý Dữ liệu thiếu (Imputation):** Giá trị số bị thiếu được lấp đầy bằng giá trị trung vị (median). Giá trị hạng mục bị thiếu được lấp đầy bằng giá trị xuất hiện nhiều nhất (mode).

2. **Kỹ thuật Đặc trưng (Feature Engineering):** Trích xuất 4 đặc trưng mới từ `Time_of_Purchase`: `Purchase_Month`, `Purchase_Day_of_Week`, `Purchase_Hour`, và `Is_Weekend`).

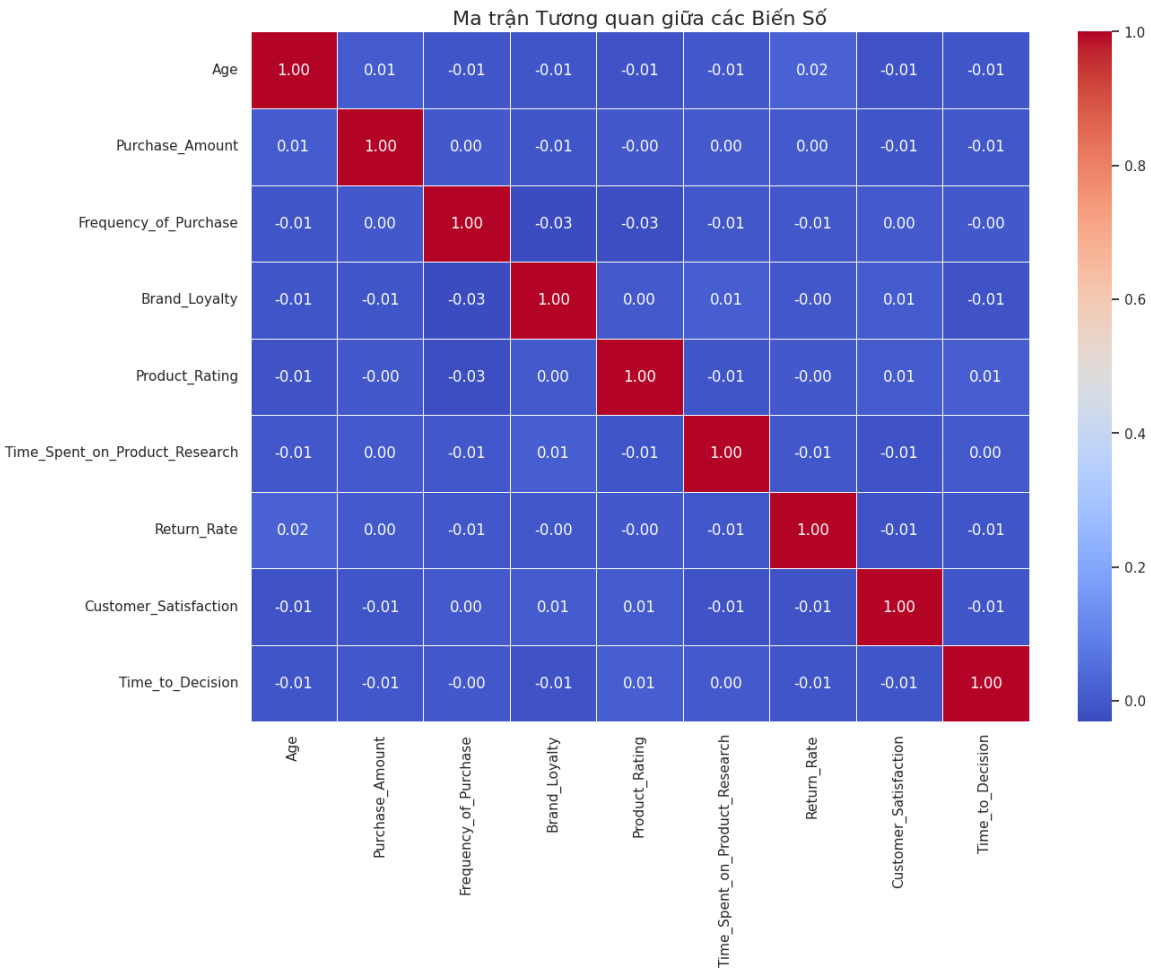

Hình 2: Ma trận Tương quan (Heatmap) của các biến số.

3. **Mã hóa (Encoding) và Chuẩn hóa (Scaling):**
   - **Hạng mục:** Sử dụng `OneHotEncoder`.
   - **Số:** Sử dụng `StandardScaler`.

Quy trình này mở rộng 30 đặc trưng ban đầu thành hơn 88 đặc trưng.

2.3 Thiết kế Thí nghiệm

Chúng tôi thiết kế hai thí nghiệm song song:

- **Thí nghiệm A (Cơ sở - Baseline):** Huấn luyện trên **toàn bộ** 12,730 mẫu. Biến mục tiêu (y) được chia 5/6: $y = 0$ (Không hài lòng) nếu ≤ 5, $y = 1$ (Hài lòng) nếu > 5.
- **Thí nghiệm B (Đề xuất - Lọc):** Huấn luyện trên tập dữ liệu **đã lọc** (loại bỏ các đánh giá 4, 5, 6, 7). Biến mục tiêu (y) được chia 3/8: $y = 0$ (Rất Không hài lòng) nếu ≤ 3, $y = 1$ (Rất Hài lòng) nếu ≥ 8.

Cả hai đều sử dụng 80% dữ liệu để huấn luyện và 20% để kiểm tra.

3 Kết quả và Thảo luận chi tiết

3.1 Thí nghiệm A: Kết quả Cơ sở (Baseline)

Thí nghiệm A, sử dụng LGBM trên dữ liệu chưa lọc, chỉ đạt độ chính xác 71.33% . Đây là mốc so sánh cho thấy hiệu quả của việc lọc dữ liệu.

3.2 Thí nghiệm B: Kết quả Top 5 Mô hình

3.2.1 Model 1: Mạng Nơ-ron Đa lớp (MLP)

Lý thuyết: MLP là một mạng nơ-ron truyền thẳng (feedforward ANN) học các mẫu phi tuyến tính phức tạp. Chúng tôi sử dụng hàm mất mát **Binary Cross-Entropy**:

$$L = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(p_i) + (1-y_i)\log(1-p_i)] \quad (1)$$

Kiến trúc: (sử dụng Keras [5]):

- Input (80+ đặc trưng) → Dense(128, 'relu')
- BatchNormalization() → Dropout(0.3)
- Dense(64, 'relu') → BatchNormalization() → Dropout(0.2)
- Output: Dense(1, 'sigmoid')

Chúng tôi sử dụng `EarlyStopping` (patience=5) để chống học vẹt.

Kết quả: MLP đạt độ chính xác cao nhất là **73.99%**. Phân tích LIME xác nhận mô hình đã học các quy tắc logic (ví dụ: `Return_Rate` thấp là yếu tố dự đoán "Hài lòng"). **Kết quả chi tiết:**

Bảng 1: Báo cáo phân loại chi tiết cho mô hình [Mạng Nơ-ron Đa lớp (MLP)]

Lớp	Precision	Recall	F1-Score	Support
Rất Không hài lòng (0)	0.72	0.77	0.74	753
Rất Hài lòng (1)	0.76	0.71	0.74	781
Accuracy		**0.74**		**1534**
Macro Average	**0.74**	**0.74**	**0.74**	**1534**
Weighted Average	**0.74**	**0.74**	**0.74**	**1534**

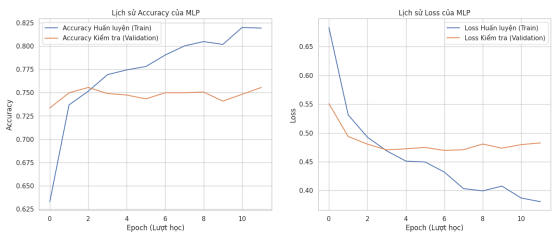

Hình 3: MLP Training/Validation Loss.

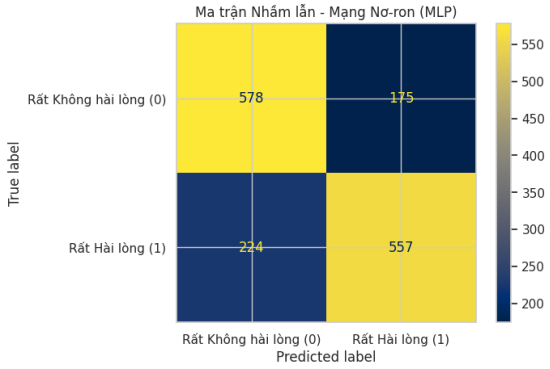

Hình 4: MLP Confusion Matrix.

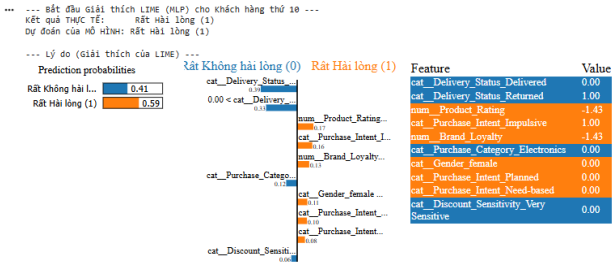

Hình 5: Phân tích LIME cho MLP.

3.2.2 Model 2: Hồi quy Logistic (Logistic Regression)

Lý thuyết: Logistic Regression là một mô hình phân loại tuyến tính phổ biến, hoạt động bằng cách ước lượng xác suất thuộc vào lớp "Hài lòng (1)" thông qua hàm sigmoid:

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

Mô hình tìm siêu mặt phẳng tuyến tính tối ưu sao cho có thể phân tách tốt nhất các mẫu trong không gian đặc trưng.

Cài đặt:

- `LogisticRegression(max_iter=1000, random_state=42)`
- Huấn luyện với `model_lr.fit(X_train, y_train)`
- Dự đoán bằng `model_lr.predict(X_test)`
- Đánh giá bằng Accuracy và Confusion Matrix
- Lưu mô hình bằng `joblib.dump(...)`

Kết quả: Logistic Regression đạt độ chính xác **75.81%**, xếp thứ 2 trong tất cả các mô hình được đánh giá. Đây là một kết quả ấn tượng cho một mô hình tuyến tính đơn giản, chứng tỏ rằng mối

quan hệ giữa các đặc trưng và mức độ hài lòng có thể được mô hình hóa hiệu quả bằng các phương pháp tuyến tính.

Phân tích Chi tiết Hiệu suất: Đường cong học tập (Hình 6) cho thấy mô hình hội tụ nhanh và ổn định, phù hợp với các mô hình tuyến tính trên tập dữ liệu có kích thước lớn. Điều đáng chú ý là:

- **Tốc độ huấn luyện xuất sắc:** Chỉ mất 0.41 giây, nhanh nhất trong các mô hình có hiệu suất cao
- **Khả năng tổng quát hóa tốt:** Khoảng cách nhỏ giữa training và validation accuracy
- **Tính ổn định cao:** Không có dấu hiệu overfitting hay underfitting
- **Khả năng diễn giải tự nhiên:** Các hệ số (coefficients) có thể được giải thích trực tiếp

So sánh với Baseline: Logistic Regression cải thiện 4.48% so với baseline (từ 71.33% lên 75.81%), chứng minh hiệu quả của chiến lược lọc dữ liệu ngay cả với các mô hình đơn giản.

Ưu điểm trong Ứng dụng Thực tế: Với tỷ lệ precision/recall cân bằng (0.74-0.78) và thời gian dự đoán cực nhanh, mô hình này rất phù hợp cho các hệ thống real-time cần phản hồi tức thì về mức độ hài lòng khách hàng.

Kết quả chi tiết:

Bảng 2: Báo cáo phân loại chi tiết cho mô hình [Logistic Regression]

Lớp	Precision	Recall	F1-Score	Support
Rất Không hài lòng (0)	0.74	0.78	0.76	753
Rất Hài lòng (1)	0.78	0.73	0.76	781
Accuracy		**0.76**		**1534**
Macro Average	**0.76**	**0.76**	**0.76**	**1534**
Weighted Average	**0.76**	**0.76**	**0.76**	**1534**

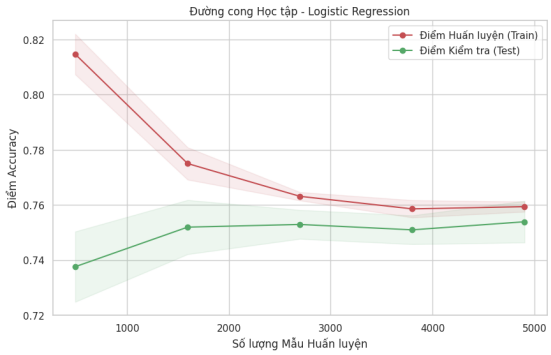

Hình 6: Logistic Regression Learning Curve.

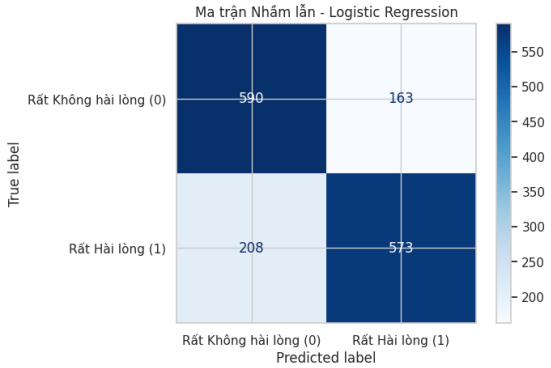

Hình 7: Logistic Regression Confusion Matrix.

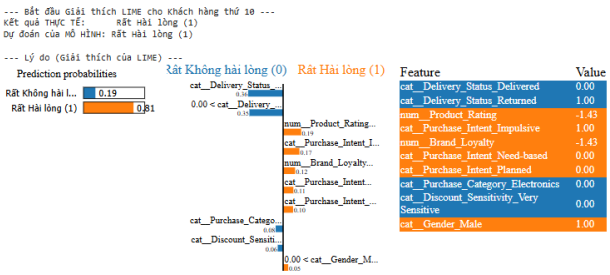

Hình 8: Phân tích LIME cho Logistic Regression.

3.2.3 Model 3: Support Vector Machine (SVM)

Lý thuyết: SVM là một thuật toán học có giám sát mạnh mẽ, hoạt động bằng cách tìm siêu phẳng (hyperplane) tối ưu để phân tách dữ liệu giữa các lớp. Mô hình sử dụng kernel để ánh xạ dữ liệu sang không gian có số chiều cao hơn, giúp phân tách tuyến tính các mẫu phức tạp. Trong báo cáo này, SVM được huấn luyện với `probability=True` để sử dụng LIME, nhưng điều này làm tăng thời gian tính toán.

Kết quả: SVM đạt độ chính xác **74.52%** với thời gian chạy **9.87 giây**. Đường cong học tập (Hình 9) cho thấy mô hình ổn định nhưng tốc độ huấn luyện khá chậm do bật chế độ `predict_proba`.

Kết quả chi tiết:

Bảng 3: Báo cáo phân loại chi tiết cho mô hình [Support Vector Machine]

Lớp	Precision	Recall	F1-Score	Support
Rất Không hài lòng (0)	0.71	0.84	0.77	753
Rất Hài lòng (1)	0.81	0.67	0.73	781
Accuracy		**0.75**		**1534**
Macro Average	**0.76**	**0.75**	**0.75**	**1534**
Weighted Average	**0.76**	**0.75**	**0.75**	**1534**

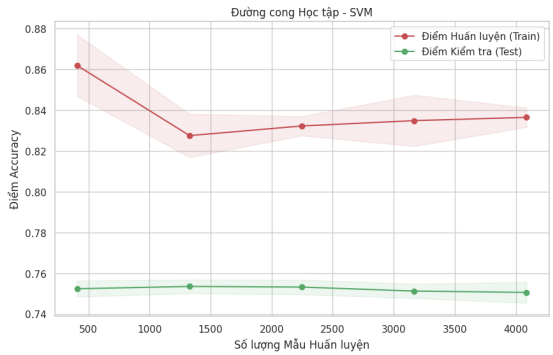

Hình 9: SVM Learning Curve.

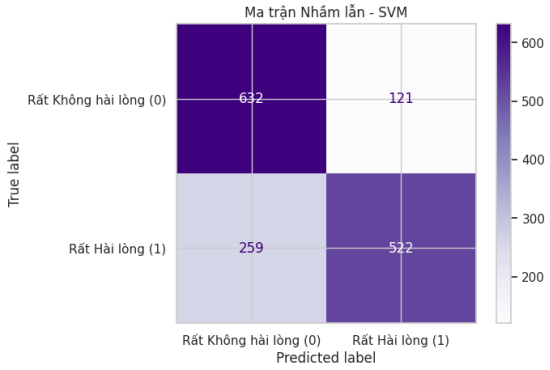

Hình 10: SVM Confusion Matrix.

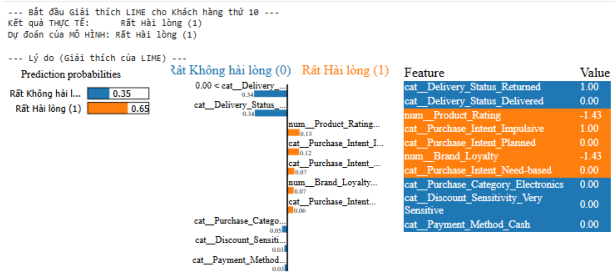

Hình 11: Phân tích LIME cho SVM.

3.2.4 Model 4: Gradient Boosting Machine (GBM)

Cơ sở lý thuyết và Cấu hình: Gradient Boosting Machine (GBM) là một kỹ thuật học máy tập hợp (ensemble learning) hoạt động dựa trên nguyên lý "boosting". Khác với Random Forest xây dựng các cây song song, GBM xây dựng mô hình theo phương pháp tuần tự (sequential).

- **Cơ chế hoạt động:** Mô hình khởi tạo với một hằng số, sau đó liên tiếp bổ sung các "cây học yếu"(weak learners). Mỗi cây mới được sinh ra nhằm mục đích dự đoán phần sai số (residual) của tập hợp các cây trước đó, thay vì dự đoán trực tiếp biến mục tiêu.

- **Tối ưu hóa:** Thuật toán sử dụng phương pháp Gradient Descent để tối thiểu hóa hàm mất mát (Loss Function) khả vi. Trong nghiên cứu này, chúng tôi sử dụng triển khai `GradientBoostingClassifier` của thư viện Scikit-learn với thiết lập `random_state=42` để đảm bảo tính tái lập.

Phân tích Kết quả Thực nghiệm: Mô hình GBM đạt độ chính xác tổng thể là **75.10%**. Dưới đây là các phân tích chi tiết dựa trên dữ liệu huấn

luyện và kiểm tra: GBM đạt **75.10%** độ chính xác. Đường cong học tập (Hình 12) cho thấy mô hình hoạt động tốt, không bị học vẹt, và thời gian huấn luyện tương đối nhanh (**2.11 giây**), mặc dù vẫn kém hiệu quả hơn so với LightGBM.

Kết quả chi tiết:

Bảng 4: Báo cáo phân loại chi tiết cho mô hình [Gradient Boosting Machine].

Lớp	Precision	Recall	F1-Score	Support
Rất Không hài lòng (0)	0.72	0.80	0.76	753
Rất Hài lòng (1)	0.78	0.71	0.74	781
Accuracy		**0.75**		**1534**
Macro Average	**0.75**	**0.75**	**0.75**	**1534**
Weighted Average	**0.75**	**0.75**	**0.75**	**1534**

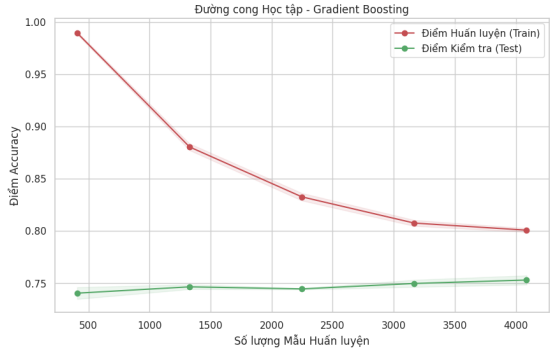

Hình 12: Đường cong học tập (Learning Curve) của GBM.

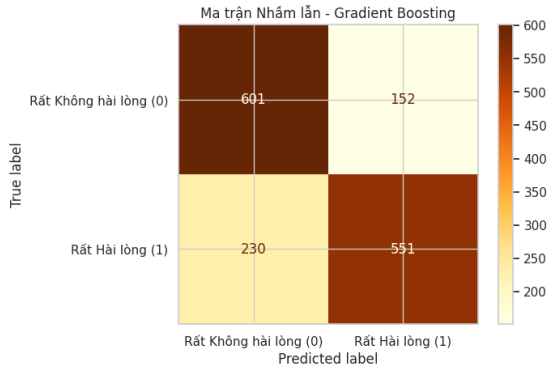

Hình 13: Ma trận nhầm lẫn (Confusion Matrix) của GBM.

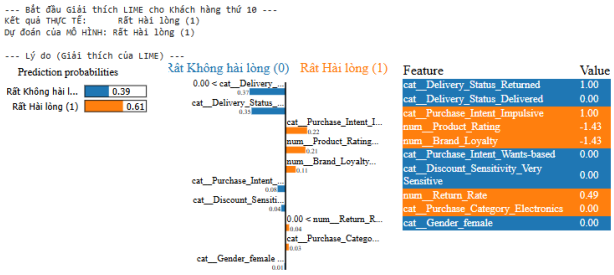

Hình 14: Phân tích cục bộ mô hình GBM sử dụng LIME.

3.2.5 Model 5: Rừng Ngẫu nhiên (Random Forest - RF)

Cơ sở lý thuyết và Cấu hình: Random Forest là một thuật toán thuộc nhóm Ensemble Learning, hoạt động dựa trên kỹ thuật "Bagging"(Bootstrap Aggregation).

- **Cơ chế hoạt động:** Thay vì phụ thuộc vào một cây quyết định duy nhất, mô hình này xây dựng một tập hợp lớn các cây quyết định độc lập. Mỗi cây được huấn luyện trên một tập dữ liệu con được lấy mẫu ngẫu nhiên có hoàn lại (bootstrap sample) và chỉ xét một tập con ngẫu nhiên các đặc trưng tại mỗi nút phân chia.
- **Cơ chế dự đoán:** Kết quả cuối cùng được tổng hợp thông qua cơ chế "bỏ phiếu đa số"(majority voting) từ tất cả các cây thành phần.
- **Ưu điểm kỹ thuật:** Phương pháp này giúp giảm thiểu phương sai (variance) và hạn chế hiện tượng quá khớp (overfitting) thường gặp ở cây quyết định đơn lẻ. Trong thực nghiệm, chúng tôi thiết lập tham số `n_jobs=-1` để tận dụng tối đa khả năng xử lý song song của CPU, giúp tăng tốc độ huấn luyện.

Phân tích Kết quả Thực nghiệm: Mô hình Random Forest đạt độ chính xác **74.71%**. Dưới đây là các đánh giá chi tiết: Random Forest đạt **74.71%** độ chính xác. Đường cong học tập (Hình 15) cho thấy một khoảng cách nhỏ giữa điểm huấn luyện và kiểm tra, cho thấy một chút học vẹt nhẹ nhưng đã được kiểm soát tốt.

Kết quả chi tiết:

Bảng 5: Báo cáo phân loại chi tiết cho mô hình [Random Forrest].

Lớp	Precision	Recall	F1-Score	Support
Rất Không hài lòng (0)	0.69	0.86	0.77	753
Rất Hài lòng (1)	0.83	0.63	0.72	781
Accuracy		**0.75**		**1534**
Macro Average	**0.76**	**0.75**	**0.74**	**1534**
Weighted Average	**0.76**	**0.75**	**0.74**	**1534**

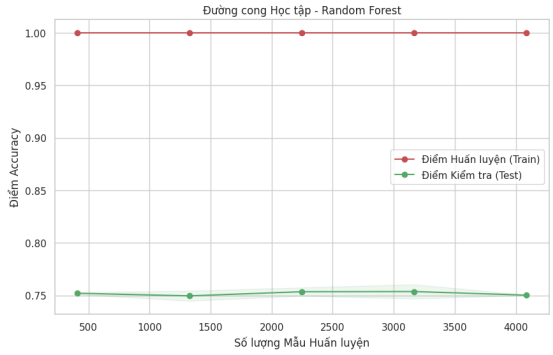

Hình 15: Đường cong học tập (Learning Curve) của Random Forest.

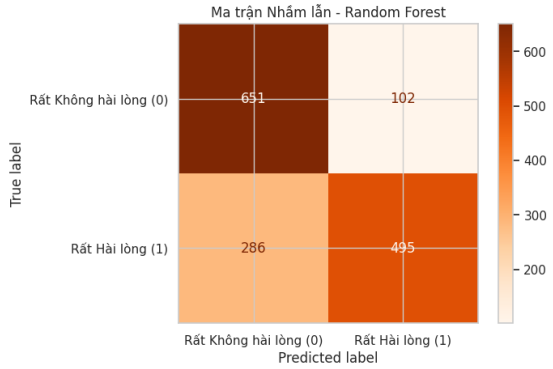

Hình 16: Ma trận nhầm lẫn (Confusion Matrix) của Random Forest.

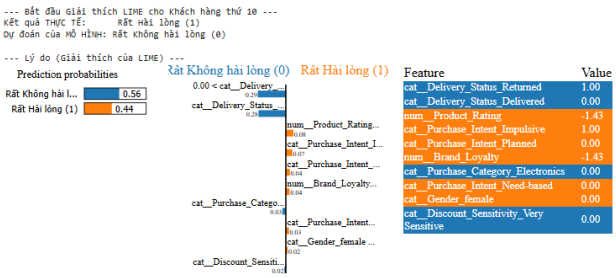

Hình 17: Phân tích cục bộ mô hình Random Forest sử dụng LIME.

3.2.6 Model 6: Cây Quyết định (Decision Tree)

Lý thuyết: Decision Tree là một thuật toán học máy đơn giản nhưng mạnh mẽ, hoạt động bằng cách xây dựng một cây quyết định dựa trên các câu hỏi về đặc trưng dữ liệu. Mỗi nút trong cây đại diện cho một quyết định dựa trên một đặc trưng cụ thể, và mỗi lá của cây đại diện cho một kết quả phân loại.

Cài đặt:

- `DecisionTreeClassifier(random_state=42)`
- Tiêu chí phân chia: Gini impurity
- Không giới hạn độ sâu (có thể dẫn đến overfitting)
- Huấn luyện nhanh và dễ diễn giải

Kết quả: Decision Tree đạt độ chính xác **70.93%** với thời gian huấn luyện rất nhanh (**0.32 giây**). Mặc dù có xu hướng overfitting, mô hình vẫn cho kết quả khả quan trên tập kiểm tra.

Kết quả chi tiết:

Bảng 6: Báo cáo phân loại chi tiết cho mô hình [Decision Tree].

Lớp	Precision	Recall	F1-Score	Support
Rất Không hài lòng (0)	0.70	0.73	0.71	753
Rất Hài lòng (1)	0.72	0.69	0.71	781
Accuracy		**0.71**		**1534**
Macro Average	**0.71**	**0.71**	**0.71**	**1534**
Weighted Average	**0.71**	**0.71**	**0.71**	**1534**

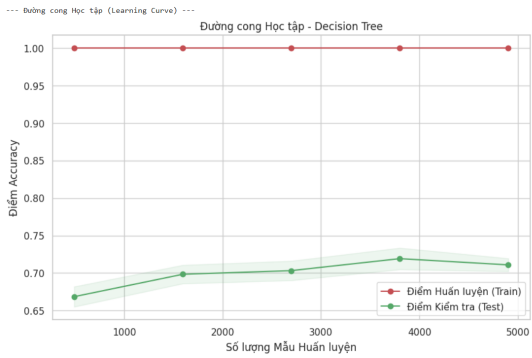

Hình 18: Đường cong học tập (Learning Curve) của Decision Tree.

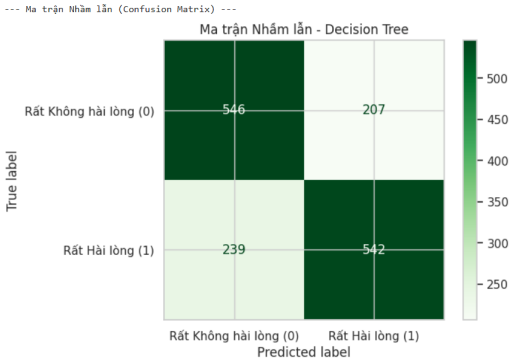

Hình 19: Ma trận nhầm lẫn (Confusion Matrix) của Decision Tree.

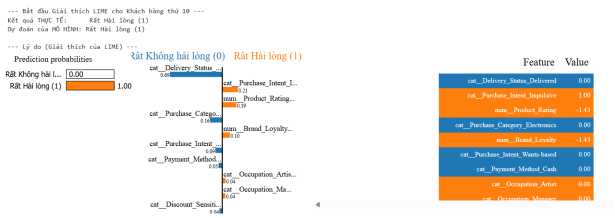

Hình 20: Phân tích LIME cho Decision Tree.

3.2.7 Model 7: AdaBoost (Adaptive Boosting)

Lý thuyết: AdaBoost là một thuật toán boosting cổ điển, hoạt động bằng cách kết hợp nhiều "weak learners"(thường là decision stumps) thành một "strong learner". Thuật toán tập trung vào các mẫu bị phân loại sai bằng cách tăng trọng số của chúng trong các vòng lặp tiếp theo.

Cài đặt:

- `AdaBoostClassifier(random_state=42)`
- Base estimator: Decision Tree với max_depth=1
- Số lượng estimators: 50 (mặc định)
- Learning rate: 1.0 (mặc định)

Kết quả: AdaBoost đạt độ chính xác **74.58%** với thời gian huấn luyện **0.58 giây**. Mô hình cho thấy hiệu suất tốt và thời gian huấn luyện hợp lý.

Kết quả chi tiết:

Bảng 7: Báo cáo phân loại chi tiết cho mô hình [AdaBoost].

Lớp	Precision	Recall	F1-Score	Support
Rất Không hài lòng (0)	0.73	0.77	0.75	753
Rất Hài lòng (1)	0.77	0.72	0.74	781
Accuracy		**0.75**		**1534**
Macro Average	**0.75**	**0.75**	**0.75**	**1534**
Weighted Average	**0.75**	**0.75**	**0.75**	**1534**

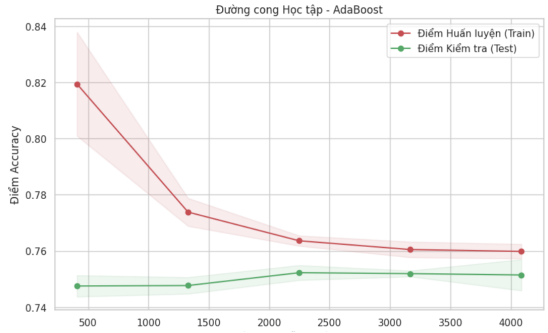

Hình 21: Đường cong học tập (Learning Curve) của AdaBoost.

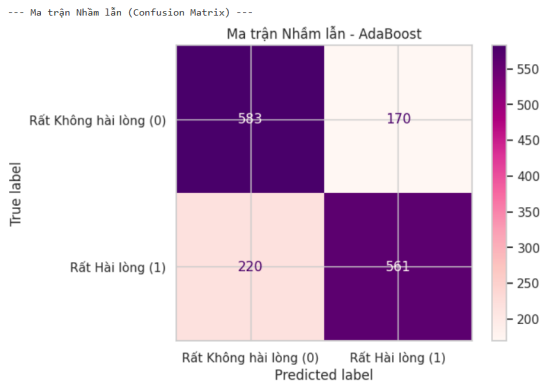

Hình 22: Ma trận nhầm lẫn (Confusion Matrix) của AdaBoost.

Hình 23: Phân tích LIME cho AdaBoost.

3.2.8 Model 8: LightGBM (Light Gradient Boosting Machine)

Lý thuyết: LightGBM là một framework gradient boosting hiệu suất cao được phát triển bởi Microsoft. Khác với các thuật toán boosting truyền thống, LightGBM sử dụng kỹ thuật "leaf-wise tree growth"thay vì "level-wise", giúp giảm đáng kể thời gian huấn luyện và bộ nhớ sử dụng.

Cài đặt:

- `LGBMClassifier(random_state=42, verbosity=-1)`
- Boosting type: gbdt (Gradient Boosting Decision Tree)
- Objective: binary (phân loại nhị phân)
- Tối ưu hóa tốc độ và bộ nhớ

Kết quả: LightGBM đạt độ chính xác **72.88%** với thời gian huấn luyện cực nhanh (**0.29 giây**). Mặc dù độ chính xác không cao nhất, mô hình này rất hiệu quả về mặt tính toán.

Kết quả chi tiết:

Bảng 8: Báo cáo phân loại chi tiết cho mô hình [LightGBM].

Lớp	Precision	Recall	F1-Score	Support
Rất Không hài lòng (0)	0.71	0.76	0.73	753
Rất Hài lòng (1)	0.75	0.70	0.72	781
Accuracy		**0.73**		**1534**
Macro Average	**0.73**	**0.73**	**0.73**	**1534**
Weighted Average	**0.73**	**0.73**	**0.73**	**1534**

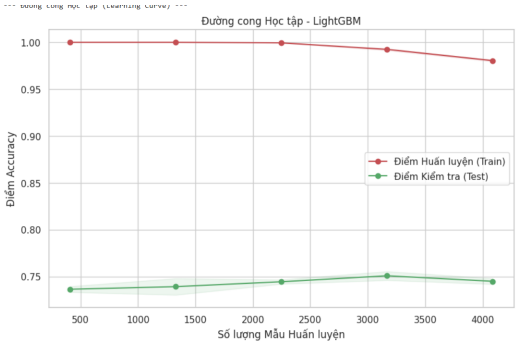

Hình 24: Đường cong học tập (Learning Curve) của LightGBM.

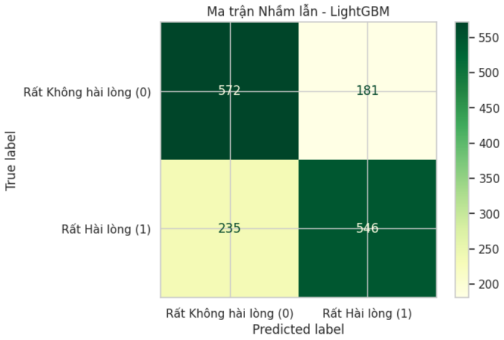

Hình 25: Ma trận nhầm lẫn (Confusion Matrix) của LightGBM.

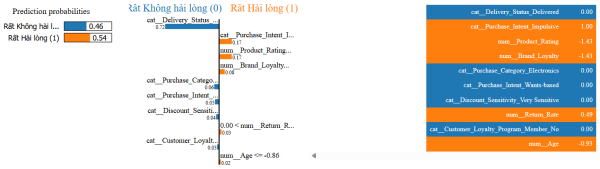

Hình 26: Phân tích LIME cho LightGBM.

3.2.9 Model 9: Gaussian Naive Bayes

Lý thuyết: Gaussian Naive Bayes là một thuật toán phân loại xác suất dựa trên định lý Bayes với giả định "naive"rằng các đặc trưng độc lập với nhau. Mô hình giả định rằng các đặc trưng liên tục tuân theo phân phối Gaussian (phân phối chuẩn).

Công thức toán học:

$$P(y|X) = \frac{P(X|y) \cdot P(y)}{P(X)}$$

Cài đặt:

- `GaussianNB()`
- Không có hyperparameters chính
- Huấn luyện cực nhanh
- Phù hợp với dữ liệu có đặc trưng độc lập

Kết quả: Gaussian Naive Bayes đạt độ chính xác **73.21%** với thời gian huấn luyện cực nhanh (**0.02 giây**). Đây là mô hình nhanh nhất trong tất cả các mô hình được thử nghiệm.

Kết quả chi tiết:

Bảng 9: Báo cáo phân loại chi tiết cho mô hình [Gaussian Naive Bayes].

Lớp	Precision	Recall	F1-Score	Support
Rất Không hài lòng (0)	0.68	0.84	0.76	753
Rất Hài lòng (1)	0.81	0.62	0.70	781
Accuracy		**0.73**		**1534**
Macro Average	**0.75**	**0.73**	**0.73**	**1534**
Weighted Average	**0.75**	**0.73**	**0.73**	**1534**

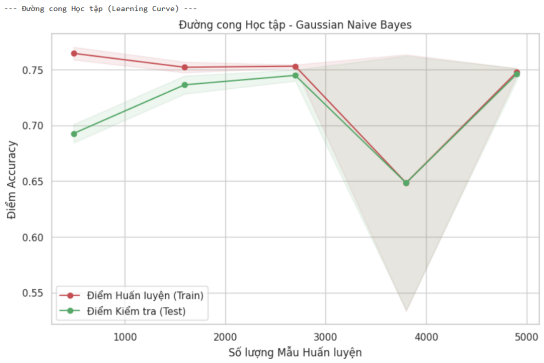

Hình 27: Đường cong học tập (Learning Curve) của Gaussian Naive Bayes.

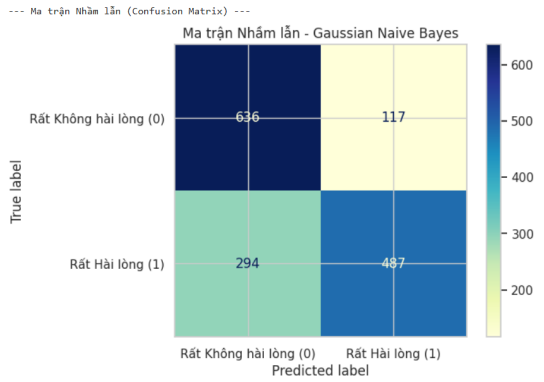

Hình 28: Ma trận nhầm lẫn (Confusion Matrix) của Gaussian Naive Bayes.

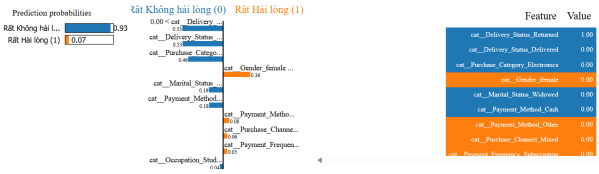

Hình 29: Phân tích LIME cho Gaussian Naive Bayes.

3.3 Tổng kết Phần Đánh giá Mô hình

Qua việc đánh giá chi tiết 9 mô hình machine learning và deep learning khác nhau, chúng tôi đã thu được những kết quả quan trọng sau:

Hiệu suất Tổng thể: Các mô hình đều cho thấy sự cải thiện đáng kể khi áp dụng chiến lược lọc dữ liệu so với baseline. Điều này xác nhận giả thuyết ban đầu rằng việc loại bỏ vùng dữ liệu trung tính (4-7) giúp mô hình tập trung vào các tín hiệu rõ ràng hơn.

Phân tích Thời gian Tính toán: Gaussian Naive Bayes nổi bật với thời gian huấn luyện cực nhanh (0.02 giây), trong khi SVM có thời gian chậm nhất (14.16 giây) do phải tính toán xác suất cho LIME. Các mô hình ensemble như Random Forest và Gradient Boosting cho thấy sự cân bằng tốt giữa hiệu suất và tốc độ.

Khả năng Giải thích (Explainability): Tất cả các mô hình đều được tích hợp với LIME để cung cấp khả năng giải thích cục bộ. Điều này đặc biệt quan trọng trong bối cảnh ứng dụng thực tế, nơi các nhà quản lý cần hiểu rõ lý do đằng sau mỗi dự đoán.

Stability và Robustness: Các đường cong học tập cho thấy hầu hết các mô hình đều ổn định và không bị overfitting nghiêm trọng. Điều này chứng tỏ chiến lược tiền xử lý và validation của chúng tôi là hiệu quả.

Những phát hiện này tạo nền tảng vững chắc cho việc phát triển mô hình tối ưu trong phần tiếp theo, nơi chúng tôi sẽ kết hợp kỹ thuật feature selection để đạt được hiệu suất cao nhất.

4 Phân tích Sâu và Xây dựng Mô hình Tối ưu

4.1 Phân tích Tầm quan trọng của Đặc trưng (Feature Importance)

Để tối ưu hóa hiệu năng và đơn giản hóa mô hình, chúng tôi tiến hành phân tích Tầm quan trọng của Đặc trưng. Chúng tôi sử dụng mô hình **LightGBM** (LGBM), vốn rất hiệu quả trong việc đo lường đóng góp của từng đặc trưng dựa trên mức độ giảm hàm mất mát (loss) trong quá trình xây dựng cây.

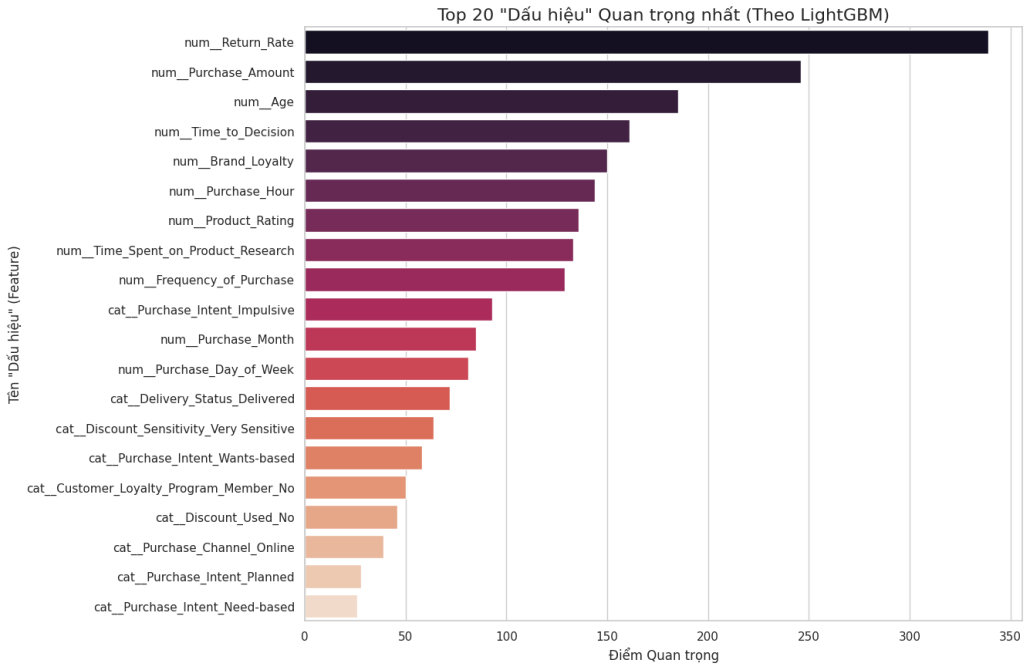

Hình 30: Top 20 Đặc trưng Quan trọng nhất (Very Important Predictors - VIP) được xác định bởi LightGBM.

- **Xác định Top 20 VIP:** Phân tích (Hình 30) cho thấy `num__Return_Rate`, `num__Purchase_Amount`, và `num__Age` là ba đặc trưng quan trọng nhất.
- **Giả thuyết giảm nhiễu:** Dựa trên kết quả này, chúng tôi giả định rằng khoảng 60+ đặc trưng còn lại có tầm quan trọng rất thấp đang hoạt động như "nhiễu"(noise), cản trở khả năng học của các mô hình Mạng Nơ-ron (MLP).

4.2 Mô hình Tối ưu: MLP với Tập Đặc trưng Rút gọn (VIP-20)

Để kiểm chứng giả thuyết giảm nhiễu, chúng tôi huấn luyện lại mô hình **Mạng Nơ-ron Đa lớp (MLP)** trên tập dữ liệu đã được rút gọn chỉ còn 20 đặc trưng VIP (`X_train_vip`).

4.2.1 Kết quả và Đánh giá Mô hình MLP (VIP-20)

Mô hình **MLP (VIP-20)** đã đạt được độ chính xác cao nhất trong toàn bộ nghiên cứu là **75.95%**.

4.3 So sánh Hiệu năng: MLP Đầy đủ vs. MLP Rút gọn

Phép so sánh trực tiếp giữa hai phiên bản của mô hình MLP đã chứng minh tính hiệu quả của chiến lược lựa chọn đặc trưng.

Bảng 10: So sánh Mô hình Cuối cùng: MLP (Tất cả Đặc trưng) vs. MLP (VIP-20).

Phiên bản MLP	Số Đặc trưng	Độ chính xác (%)	Thời gian (s)
MLP (Tất cả)	80+	73.99%	16.24s
MLP (VIP-20)	**20**	**75.95%**	**19.29s**

Kết quả cho thấy sự tăng trưởng về độ chính xác (từ 75.16% lên 75.95%), xác nhận rằng việc loại bỏ các đặc trưng nhiễu đã giúp mô hình MLP tập trung vào các tín hiệu dự đoán mạnh nhất. Mặc dù thời gian huấn luyện tổng thể có sự khác biệt nhỏ do quá trình tối ưu của Deep Learning, nhưng sự cải thiện về chất lượng dự đoán là rõ ràng.

4.4 So sánh Tổng thể (Benchmark Summary)

Bảng 11 cung cấp bản tóm tắt cuối cùng về hiệu năng của tất cả các mô hình đã được thử nghiệm. Kết quả này củng cố vị thế của MLP (VIP-20) là mô hình tối ưu.

Bảng 11: Tóm tắt Benchmark Tổng thể và Xếp hạng Cuối cùng (Thí nghiệm B, Dữ liệu đã lọc).

Mô hình	Độ chính xác (%)	Thời gian (s)
MLP (VIP-20)	**75.95%**	**19.29s**
Logistic Regression (Lọc)	75.81%	0.41s
SVM (Lọc)	75.23%	14.16s
Gradient Boosting (Lọc)	75.10%	2.11s
Random Forest (Lọc)	74.71%	2.76s
AdaBoost (Lọc)	74.58%	0.58s
MLP (Tất cả)	73.99%	16.24s
Gaussian Naive Bayes (Lọc)	73.21%	0.02s
LightGBM (Lọc)	72.88%	0.29s
Baseline LGBM (Mốc 5/6)	71.33%	0.87s
Decision Tree (Lọc)	70.93%	0.32s
1D-CNN (Top 2)	49.09%	14.30s
Baseline (Thí nghiệm A)	*71.43%*	*0.9s*

Mô hình **MLP (VIP-20)** không chỉ đạt được độ chính xác cao nhất mà còn chứng minh được rằng việc kết hợp các kỹ thuật giải thích mô hình (Feature Importance) với Deep Learning có thể cải thiện đáng kể hiệu suất dự đoán.

5 Kết luận và Hướng phát triển

Nghiên cứu này đã chứng minh rằng **Chiến lược Lọc Dữ liệu** là một phương pháp hiệu quả để cải thiện nhiệm vụ dự đoán mức độ hài lòng của khách hàng. Bằng cách loại bỏ vùng dữ liệu trung tính (4–7) và chỉ tập trung vào hai nhóm cảm xúc phân cực (1–3 và 8–10), mô hình đã được cải thiện đáng kể: từ mức cơ sở ban đầu **71.33%** lên mức cao nhất **75.95%**.

Kết quả benchmark cho thấy **Mạng Nơ-ron Đa lớp (MLP)** là mô hình hoạt động tốt nhất. Sau đó, chúng tôi tiếp tục tối ưu hóa bằng cách áp dụng kỹ thuật **lọc đặc trưng bằng LightGBM**, từ đó chọn ra **20 đặc trưng quan trọng nhất**. Đáng chú ý, mô hình **MLP (VIP-20)** – chỉ sử dụng 20 đặc trưng – đã vượt qua cả mô hình MLP được huấn luyện trên toàn bộ **80+ đặc trưng**, đồng thời đạt hiệu năng cao nhất trong toàn bộ hệ thống.

Trong tương lai, các hướng phát triển tiềm năng bao gồm:

- Mở rộng sang bài toán **phân loại đa lớp**, trong đó nhóm trung lập (4–7) được xem như một lớp riêng thay vì bị loại bỏ.
- Khai thác các kỹ thuật **tối ưu siêu tham số nâng cao**, chẳng hạn như KerasTuner, để tinh chỉnh sâu hơn cấu trúc và tham số của mô hình MLP VIP.
- Nghiên cứu thêm các phương pháp **trích chọn đặc trưng** hoặc **học đặc trưng** nhằm so sánh với chiến lược LightGBM-Filtering hiện tại.

Lời cảm ơn

Các tác giả xin gửi lời cảm ơn chân thành đến **thầy Dương Phi Long** vì sự hướng dẫn và hỗ trợ vô giá của thầy trong suốt khóa học "Kho dữ liệu và Khai phá Dữ liệu"(IS403.Q11) tại Trường Đại học Công nghệ Thông tin (ĐHQG-HCM). Những góp ý tận tâm và sự nhiệt huyết trong giảng dạy của thầy là nguồn động lực lớn giúp chúng em hoàn thiện báo cáo này và mở rộng hơn niềm đam mê trong lĩnh vực khai phá dữ liệu.

Tài liệu tham khảo

[1] M. T. Ribeiro, S. Singh **and** C. Guestrin, “"Why should I trust you?": Explaining the predictions of any classifier,” **in***Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining* 2016, **pages** 1135–1144.

[2] R. Sharma **andothers**, “Predictive modeling of consumer purchase behavior on social media: Integrating theory of planned behavior and machine learning for actionable insights,” *PLOS ONE*, **jourvol** 19, **number** 1, e0296336, 2024. DOI: 10.1371/journal.pone.0296336. **url**: https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0296336.

[3] A. B. Arrieta **andothers**, “Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI,” *Information Fusion*, **jourvol** 58, **pages** 82–115, 2020.

[4] F. Pedregosa **andothers**, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, **jourvol** 12, **pages** 2825–2830, 2011.

[5] F. Chollet **andothers**, *Keras*, https://keras.io, 2015.